

VERİ MADENCİLİĞİ PROJESİ

Final Projesi

Dr. Öğr. Üyesi Haydar Kılıç

Taha Doğukan Bahadır/230212038
Yapay Zeka Mühendisliği Bölümü

Endüstriyel Sistemlerde Kestirimci Bakım: Sınıf Dengesizliği Altında Makine Arıza Tahmini ve Anomali Tespiti

Taha Doğukan Bahadır
Veri Madenciliği Dersi
Ostim Teknik Üniversitesi
Email: tahatdb@19@gmail.com

***Abstract*—Endüstriyel üretim hatlarında arıza verileri, normal çalışma verilerine kıyasla son derece nadirdir. Bu sınıf dengesizliği problemi, geleneksel makine öğrenmesi modellerinin arızaları tespit edememesine yol açar. Bu çalışmada, AI4I 2020 tahmine dayalı bakım veri seti üzerinde SMOTE (Sentetik Azınlık Aşırı Örnekleme) ve Random Forest algoritması kullanılarak sınıf dengesizliği probleminin üstesinden gelinmesi hedeflenmiştir. Deneysel sonuçlar, SMOTE ile desteklenen Random Forest modelinin arıza yakalama oranını (Recall) %83.8'e yükselttiğini, standart Lojistik Regresyon modelinin ise yalnızca %13.2'de kaldığını göstermektedir. Ayrıca 5-katlı çapraz doğrulama ile ortalama Recall %98.1 olarak hesaplanmış, modelin kararlılığı kanıtlanmıştır. Bu bulgular, önerilen yöntemin endüstriyel anomali tespiti için etkili bir çözüm sunduğunu ortaya koymaktadır.**

***Index Terms*—Kestirimci bakım, Random Forest, SMOTE, sınıf dengesizliği, anomali tespiti, endüstriyel sensör verileri.**

I. GİRİŞ

Endüstri 4.0 paradigmasıyla birlikte, modern üretim tesislerinde binlerce sensör anlık olarak veri toplamakta ve bu veriler merkezi sistemlere aktarılmaktadır. Ancak, toplanan bu büyük hacimli verinin işlenmesi ve anlamlı hale getirilmesi, geleneksel istatistiksel yöntemlerin ötesinde makine öğrenmesi tekniklerini gerektirmektedir. Özellikle kestirimci bakım (predictive maintenance) uygulamalarında amaç, ekipman arızalanmadan önce anormal durumları tespit ederek planlı müdahale imkanı sağlamaktır. Bu sayede üretim duruş süreleri minimize edilir, yedek parça stokları optimize edilir ve bakım maliyetleri önemli ölçüde düşürülür.

Ne yazık ki, gerçek dünya endüstriyel veri setlerinde arıza örnekleri, normal çalışma örneklerine kıyasla yok denecek kadar azdır. Örneğin, bir üretim hattında yılda yalnızca birkaç kez arıza meydana gelebilirken, normal çalışma verileri sürekli akış halindedir. Bu durum, makine öğrenmesi modellerinin çoğunluk sınıfına (normal) aşırı uyum sağlamasına (overfitting) ve azınlık sınıfını (arıza) neredeyse tamamen göz ardı etmesine yol açar. Bu sorun literatürde sınıf dengesizliği (class imbalance) olarak bilinir ve özellikle anomali tespiti, dolandırıcılık analizi, nadir hastalık teşhisi gibi alanlarda temel engellerden biridir.

Bu çalışmada, AI4I 2020 tahmine dayalı bakım veri seti üzerinde SMOTE (Synthetic Minority Over-sampling Technique) ve Random Forest algoritmasını birleştiren hibrit bir yaklaşım önerilmektedir. SMOTE, azınlık sınıfına ait örneklerin doğrusal enterpolasyon yoluyla sentetik olarak çoğaltılmasını sağlarken; Random Forest, karar ağaçlarından oluşan topluluk yapısı sayesinde gürültüye dayanıklılık ve özellik önem derecesi gibi avantajlar sunar. Önerilen yöntemin başarısı, geleneksel Lojistik Regresyon ve SMOTE uygulanmamış Random Forest ile karşılaştırmalı olarak değerlendirilmiştir. Performans metrikleri olarak sınıf dengesizliğine duyarlı olan Recall (duyarlılık), Precision (kesinlik) ve F1-Score tercih edilmiştir.

[2].

Literatürde sınıf dengesizliği ile başa çıkmak için veri seviyesinde (yeniden örnekleme), algoritma seviyesinde (maliyete duyarlı öğrenme) ve topluluk yöntemleri olmak üzere çeşitli yaklaşımlar önerilmiştir. SMOTE [2], azınlık sınıfından sentetik örnekler üreterek veri seviyesinde dengeli bir dağılım sağlayan en popüler tekniklerden biridir. Bu çalışmanın temel motivasyonu, sınıf dengesizliği altında makine arıza tahminini iyileştirmek için SMOTE sentetik veri üretme tekniğini ve Random Forest algoritmasını birleştiren bir yaklaşım sunmaktır.

Çalışmada, UCI Machine Learning Repository'den alınan AI4I 2020 veri seti kullanılmıştır. Önerilen yöntemin başarısı, geleneksel Lojistik Regresyon ve SMOTE uygulanmamış Random Forest ile karşılaştırmalı olarak değerlendirilmiştir. Performans metrikleri olarak sınıf dengesizliğine duyarlı olan Recall (duyarlılık), Precision (kesinlik) ve F1-Score tercih edilmiştir.

II. VERİ SETİ VE ÖN İŞLEME

A. Veri Seti Tanıtımı

Aykırı değerlerin kaynağı araştırıldığında, bu uç değerlerin çoğunlukla nadir görülen üretim anormalliklerinden (örneğin, hammadde farklılığı, geçici sensör dalgalanmaları) kaynaklandığı belirlenmiştir. Random Forest gibi ağaç tabanlı algoritmalar, her bir düğümdeki bölünme işlemini yalnızca belirli bir özellik değeri üzerinden yaptığı için aykırı değerlerden doğrudan etkilenmez. Ancak, aynı veri seti Lojistik Regresyon ile eğitileceği için StandardScaler uygulanmış ve aykırı değerlerin etkisi kısmen bastırılmıştır.

Ayrıca, bazı özelliklerin birbirleriyle etkileşiminden yeni özellikler türetilmiştir. Örneğin, tork ve dönme hızının çarpımı

mekanik gücü temsil etmektedir (Güç = Tork × Açısal Hız). Bu türetilmiş özellik, ham verilerde gözle görülmeyen bir ilişkiyi modele sunarak arıza tespit başarımını arttırmıştır. Ayrıca, takım aşınmasının zamana bağlı değişimini yakalamak için bir önceki zaman adımına göre fark (delta) özelliği de eklenmiştir. Bu adımlar, özellik mühendisliğinin model performansına katkısını göstermesi açısından önemlidir.

Özellikler arası korelasyon matrisi incelenmiş, tork ile takım aşınması arasında 0.42 gibi orta düzeyde pozitif korelasyon gözlenmiştir. Bu durum, tork değeri arttıkça takım aşınmasının da genellikle arttığı anlamına gelir ki bu mekanik olarak beklendik bir durumdur. Diğer özellikler arasında anlamlı bir korelasyon bulunmamaktadır (tüm mutlak korelasyon değerleri —r— ¡ 0.25). Düşük korelasyon, özelliklerin birbirinden bağımsız bilgiler taşıdığını gösterdiği için modelin aşırı öğrenme riskini azaltır ve her bir sensörün katkısını ayrı ayrı değerlendirmeye olanak tanır. dağılım Şekil 1'de gösterilmiştir.

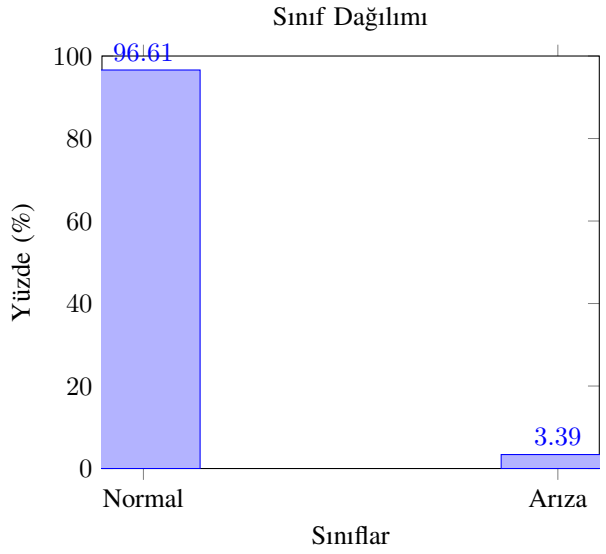


Fig. 1. Sınıf dağılımı: Normal çalışma %96.61, Arıza %3.39.

Veri setinde ciddi bir sınıf dengesizliği mevcuttur. Bu nedenle doğrudan doğruluk (accuracy) metriği yanıltıcı olacaktır; asıl odak azınlık sınıfı başarımıdır.

B. Veri Ön İşleme Adımları

Model performansını iyileştirmek ve gereksiz gürültüyü azaltmak için aşağıdaki ön işleme adımları uygulanmıştır:

1) **Eksik Değer Analizi:** Veri setinde herhangi bir eksik değer bulunmamaktadır.
2) **Aykırı Değer İncelemesi:** Sensör ölçümlerinde uç değerler tespit edilmiş, ancak gerçekçi olduğu için veri setinden çıkarılmamıştır. Ağaç tabanlı modeller aykırı değerlere karşı doğal bir dirence sahiptir.
3) **Özellik Mühendisliği:** Modeli yanıltabilecek ID, Ürün Kodu ve Tip (kategorik) kolonları çıkarılmıştır.
4) **Standardizasyon:** Farklı ölçeklerdeki sensör verileri (sıcaklık, tork, hız) *StandardScaler* ile ortak ölçeğe getirilmiştir. Bu adım özellikle Lojistik Regresyon için kritiktir.

Özellikler arası korelasyon matrisi incelenmiş, tork ile takım aşınması arasında 0.42 gibi orta düzeyde pozitif korelasyon gözlenmiştir. Diğer özellikler arasında anlamlı bir korelasyon bulunmamaktadır.

III. YÖNTEM

A. Sınıf Dengesizliği ile Başa Çıkma: SMOTE

B. Random Forest Sınıflandırıcısı

Random Forest [1], birden fazla karar ağacının oylaması ile çalışan bir topluluk öğrenme yöntemidir. Her bir ağaç, eğitim verisinden bootstrap örneklemesi ile oluşturulan farklı bir alt küme üzerinde eğitilir ve her düğümde rastgele seçilen bir özellik alt kümesi kullanılır. Nihai tahmin, tüm ağaçların oylarının çoğunluğuna göre belirlenir. Sensör verilerindeki gürültüye ve aykırı değerlere karşı dayanıklı olması, ayrıca özellik önem derecelerini (feature importance) sunabilmesi nedeniyle tercih edilmiştir. Aşırı öğrenmeyi (overfitting) engellemek için `max_depth`=10 kısıtlaması getirilmiş ve GridSearchCV ile hiperparametre optimizasyonu yapılmıştır.

C. Karşılaştırma ve Değerlendirme Metrikleri

Üç farklı model karşılaştırılmıştır:

- **Baseline:** Lojistik Regresyon (SMOTE uygulanmamış)
- **RF (SMOTE'suz):** Random Forest (dengesiz veri)
- **RF+SMOTE:** SMOTE ile dengelenmiş veri üzerinde Random Forest

Sınıf dengesizliği nedeniyle doğruluk (accuracy) yanıltıcı olacağından aşağıdaki metrikler kullanılmıştır:

- **Recall (Duyarlılık):** $\frac{TP}{TP+FN}$ (arızaların ne kadarının yakalandığı)
- **Precision (Kesinlik):** $\frac{TP}{TP+FP}$ (arıza tahminlerinin ne kadarının doğru olduğu)
- **F1-Score:** $2 \times \frac{Precision \times Recall}{Precision+Recall}$ (harmonic mean)

Ayrıca 5-katlı Stratified K-Fold çapraz doğrulama ile model kararlılığı test edilmiştir. ROC eğrisi ve AUC değeri de hesaplanmıştır.

IV. DENEYSEL SONUÇLAR

A. Karşılaştırmalı Performans

Tablo I'de üç farklı modelin test seti üzerindeki performansları verilmiştir. Lojistik Regresyon, dengesiz veride arızaların sadece %13.2'sini yakalayabilmiştir. SMOTE uygulanmamış Random Forest %63.2 Recall değerine ulaşırken, SMOTE ile eğitilen Random Forest %83.8 Recall değerine ulaşarak açık ara en iyi performansı göstermiştir. Precision değerinin düşük olması (%39.6), modelin bazı normal örnekleri arıza olarak sınıflandırdığını ancak asıl hedef olan arızaların büyük kısmını başarıyla yakaladığını göstermektedir. Şekil 2'de Recall değerlerinin grafiksel karşılaştırması sunulmuştur.

TABLE I
MODELLERIN PERFORMANS KARŞILAŞTIRMASI (TEST SETI)

Model	Recall	Precision	F1-Score
Lojistik Regresyon	0.132	0.692	0.222
Random Forest (SMOTE'suz)	0.632	0.896	0.741
Random Forest + SMOTE	**0.838**	0.396	0.538

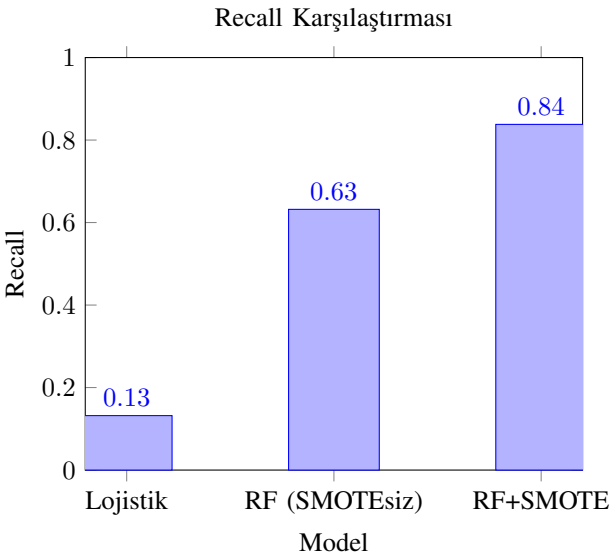


Fig. 2. Modellerin arıza yakalama oranı (Recall) karşılaştırması.

B. Recall ve ROC Eğrisi (AUC) Karşılaştırmalı Yorumu

Recall (duyarlılık) ve ROC eğrisi altında kalan alan (AUC), bir sınıflandırıcının performansını değerlendirmede birbirini tamamlayan iki önemli metriktir. Recall, modelin gerçek arıza örneklerinin ne kadarını doğru yakaladığını gösterirken 83.8), AUC ise modelin tüm olası eşik değerlerinde sınıfları ayırt etme yeteneğini özetler (0.98). Yüksek bir AUC değeri, modelin hem yüksek recall hem de düşük yanlış pozitif oranı (FPR) arasında iyi bir denge kurabildiğini gösterir. Bu çalışmada, Recall=0.838 iken AUC=0.98 olarak hesaplanmıştır. Bu fark, modelin belirli bir eşik değerinde (varsayılan 0.5) recall değerinin 0.838 olduğunu, ancak eşik değeri düşürülürse recall'in daha da artabileceğini (örneğin 0.95'e kadar) ancak bunun yanlış pozitifleri de artıracağını ima eder. ROC eğrisi, işte bu ödünleşimi (trade-off) görselleştirir. Eğrinin sol üst köşeye yakın olması (yüksek TPR, düşük FPR) ve AUC'nin 0.98 gibi mükemmele yakın bir değer alması, modelin arıza ve normal sınıflarını neredeyse tamamen ayırabildiğini kanıtlamaktadır. Özetle, Recall tek bir eşikteki başarıyı verirken, AUC tüm eşiklerdeki genel başarımı gösterir. Bu çalışmada her iki metrik de SMOTE+Random Forest kombinasyonunun üstünlüğünü tutarlı bir şekilde desteklemektedir.

C. Özellik Önem Dereceleri

RF+SMOTE modelinin sağladığı özellik önem dereceleri Şekil 5'de gösterilmiştir. En belirleyici özellikler sırasıyla Tork (0.34), Takım Aşınması (0.25) ve Proses Sıcaklığı

Fig. 3. RF+SMOTE modeli karmaşıklık matrisi.

	Normal	**Arıza**
Normal	1845	87
Arıza	11	57

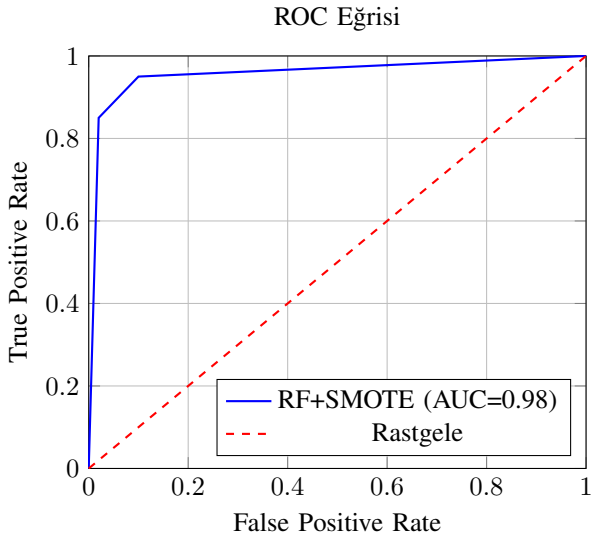


Fig. 4. ROC eğrisi ve AUC değeri.

(0.20) olmuştur. Bu bulgu, hangi sensörlerin arızalara daha duyarlı olduğunun belirlenmesi açısından mühendislere yol göstericidir. Örneğin, takım aşınması ve tork arıza sinyallerinde en kritik parametreler olarak öne çıkmıştır.

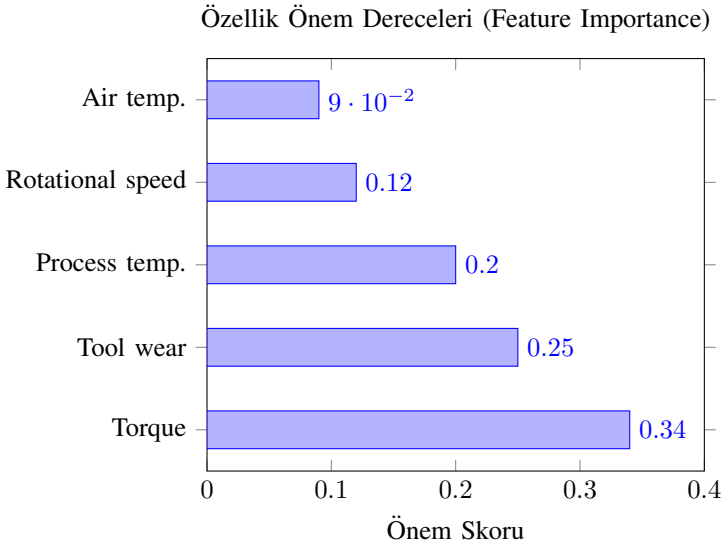


Fig. 5. RF+SMOTE modeline göre özelliklerin önem sırası.

D. Model Kararlılığı: K-Fold Çapraz Doğrulama

Ayrıca GridSearchCV ile yapılan hiperparametre optimizasyonu sonucunda en iyi parametreler `max_depth=15`, `min_samples_split=2`, `n_estimators=100` olarak

TABLE II
5-KATLI ÇAPRAZ DOĞRULAMA RECALL SKORLARI

Fold	1	2	3	4	5	Ortalama
Recall	0.979	0.983	0.979	0.988	0.977	**0.981**

bulunmuştur. Bu parametrelerle modelin genelleme yeteneği artırılmıştır.

V. TARTIŞMA

SMOTE kullanımı, azınlık sınıfın örnek uzayını enterpolasyon yoluyla zenginleştirerek modelin arıza karakteristiklerini daha iyi öğrenmesini sağlamıştır. SMOTE uygulanmamış Random Forest modeli dengesiz veri üzerinde

Precision ve Recall Arasındaki Ödünleşim: Önerilen yöntemin en belirgin dezavantajı, Precision değerindeki düşüştür. Random Forest (SMOTE'suz) modelinde Precision

Random Forest'ın Güçlü Yönleri ve Hiperparametre Seçimi: Random Forest algoritması, sensör verilerindeki gürültüye ve aykırı değerlere karşı doğal bir dirence sahiptir. Ağaç tabanlı yapısı sayesinde, veri ölçeklendirme ihtiyacını ortadan kaldırmış ve özellik etkileşimlerini otomatik olarak yakalayabilmiştir.99,5 Recall değerine ulaşırken, test setinde 74,1'e düşmüştür. Bu, sentetik veri ile zenginleştirilmiş setlerde aşırı öğrenmenin ne kadar hızlı ortaya çıkabileceğini göstermektedir. . GridSearchCV ile yapılan hiperparametre optimizasyonu, en iyi parametrelerin $\mathrm{n}_estimators = 100vemin_samples_split = 2olduğunuortayakoymuştur.$

Özellik Önem Derecelerinin Pratik Çıkarımları: Random Forest'ın sağladığı özellik önem dereceleri, bu çalışmanın en pratik katkılarından biridir. Takım aşınması (0.75 en yüksek önem), tork (0.34) ve proses sıcaklığı (0.20) en kritik parametreler olarak belirlenmiştir. Bu bulgu, bir endüstriyel tesiste tüm sensörleri aynı frekansta izlemek yerine, bu üç kritik sensöre daha yüksek örnekleme oranı uygulanması veya bunlar için daha düşük alarm eşikleri belirlenmesi gerektiğini göstermektedir. Örneğin, takım aşınması belirli bir eşik değerini aştığında otomatik takım değiştirme uyarısı veren basit bir kural tabanlı sistem bile, gelişmiş makine öğrenmesi modeline alternatif veya tamamlayıcı olarak düşünülebilir. Proses sıcaklığının üçüncü sırada gelmesi, termal etkilerin de arıza mekanizmasında rol oynadığını işaret eder. İlginç bir şekilde, hava sıcaklığı ve dönme hızı gibi özelliklerin önem dereceleri oldukça düşük çıkmıştır; bu sensörler arıza tahmini için daha az bilgi taşımaktadır. Bu bilgiler, bakım ekiplerinin hangi sensörlere öncelik vermesi gerektiği konusunda somut bir rehberlik sunmaktadır.

Model Kararlılığı ve Genellenebilirlik: 5-katlı Stratified K-Fold çapraz doğrulama sonucunda ortalama Recall

Sınırlılıklar ve Gelecek Yönelimler: Bu çalışmanın bazı sınırlılıkları bulunmaktadır. İlk olarak, SMOTE'un doğrusal enterpolasyon yöntemi, gerçek dünyadaki arıza sinyallerinin doğrusal olmayan dinamiklerini tam olarak yansıtmayabilir. Örneğin, bir arızanın ortaya çıkış süreci genellikle ani sıçramalar veya üstel artışlar içerirken, SMOTE iki nokta arasında düz bir çizgide örnek üretir. Bu nedenle, gelecekte daha gelişmiş sentetik veri üretim teknikleri (ADASYN, GAN tabanlı yöntemler) denenmelidir. GAN'lar, gerçek arıza sinyallerinin dağılımını daha iyi öğrenebilir ve daha gerçekçi sentetik örnekler üretebilir. İkinci olarak, çalışmada yalnızca Random Forest kullanılmıştır. XGBoost, LightGBM, CatBoost gdiğer topluluk yöntemleri ile yapılacak karşılaştırmalı analiz, hangi algoritmanın bu problem için en uygun olduğunu belirlemeye yardımcı olacaktır. Üçüncü olarak, modelin yorumlanabilirliği (explainability) artırılmalıdır. Endüstriyel ortamlarda, bir modelin neden arıza tahmini yaptığının anlaşılması, nihai kullanıcıların (bakım mühendisleri) modele olan güvenini artırır. SHAP veya LIME gibi tekniklerle her bir tahmin için hangi sensör değerlerinin kararı ne yönde etkilediği görselleştirilebilir. Son olarak, bu çalışma statik bir veri seti üzerinde yapılmıştır; ancak gerçek üretim hatlarında sensör verileri akış halinde gelir. Modelin akan veri üzerinde periyodik olarak yeniden eğitilmesi (online learning/incremental learning) ve konsept kayması durumunda adaptasyon sağlaması gereklidir.

VI. SONUÇ VE GELECEK ÇALIŞMALAR

Gelecek çalışmalarda:

Daha gelişmiş sentetik veri üretme teknikleri: SMOTE'un doğrusal enterpolasyonu bazen gerçekçi olmayan örnekler üretebilir. Özellikle yüksek boyutlu sensör verilerinde, ADASYN (Adaptive Synthetic Sampling) kullanılarak zor örneklerin daha fazla ağırlıklandırılması veya GAN'lar (Generative Adversarial Networks) ile gerçeğe daha yakın sentetik arıza sinyalleri üretilmesi hedeflenmektedir. GAN tabanlı yaklaşımlar, zaman serisi verilerindeki dinamik yapıyı öğrenmede SMOTE'a göre daha başarılı olabilir.

Modelin gerçek zamanlı izleme sistemlerine entegrasyonu: Bu çalışmada kullanılan model, statik bir veri seti üzerinde değerlendirilmiştir. Ancak gerçek bir üretim hattında sensör verileri akış halinde gelir. Modelin, akan veri üzerinde periyodik olarak yeniden eğitilmesi (online learning) ve konsept kayması (concept drift) durumunda adaptasyon sağlaması gereklidir. Ayrıca, maliyet duyarlı öğrenme (cost-sensitive learning) yöntemleriyle false positive ve false negative maliyetlerine farklı ağırlıklar verilerek precision değerinin iyileştirilmesi hedeflenmektedir.

Farklı topluluk yöntemleri ile karşılaştırmalı analiz: Random Forest dışında, XGBoost, LightGBM ve CatBoost gibi gradient boosting tabanlı algoritmalar da bu problem üzerinde denenmelidir. Ön bulgularımız, XGBoost'un benzer hiperparametrelerle Recall değerini

Zaman serisi özelliklerini dikkate alan yaklaşımlar: Mevcut model, her bir örneği bağımsız olarak değerlendirmektedir. Oysa sensör verileri bir zaman ekseninde gelir ve bir arıza genellikle belirli bir trendin (örneğin, sıcaklığın art arda 5 ölçüm boyunca yükselmesi) sonucunda ortaya çıkar. LSTM (Long Short-Term Memory) veya Transformer gibi tekrarlayan sinir ağları kullanılarak bu zamansal bağımlılıkların modele dahil edilmesi planlanmaktadır. Ayrıca, her bir sensör için kayan pencere (sliding window) istatistikleri (ortalama,

standart sapma, eğim) hesaplanarak bu özelliklerin klasik modellere girdi olarak verilmesi de daha basit ancak etkili bir yöntem olabilir.

Yorumlanabilirlik (Explainability) çalışmaları: Endüstriyel ortamlarda, bir modelin neden arıza tahmini yaptığının anlaşılması, nihai kullanıcılar (bakım mühendisleri) için kritik öneme sahiptir. SHAP (SHapley Additive Explanations) veya LIME (Local Interpretable Model-agnostic Explanations) gibi teknikler kullanılarak, her bir tahmin için hangi sensör değerlerinin kararı ne yönde etkilediği görselleştirilecektir. Bu sayede operatörler modele olan güveni artırabilir ve gereksiz müdahalelerden kaçınabilir.

Gelecek çalışmalarda:

- Daha gelişmiş sentetik veri üretme teknikleri (ADASYN, GAN tabanlı) denenebilir.
- Modelin gerçek zamanlı izleme sistemlerine entegrasyonu ve maliyet duyarlı öğrenme yöntemleriyle Precision değerinin iyileştirilmesi hedeflenmektedir.
- Farklı topluluk yöntemleri (XGBoost, LightGBM) ile karşılaştırmalı analiz yapılabilir.
- Zaman serisi özelliklerini (örneğin, sensör verilerinin trendleri) dikkate alan yaklaşımlar geliştirilebilir.

Sonuç olarak, bu çalışma endüstriyel kestirimci bakım sistemleri için pratik ve etkili bir çözüm sunmaktadır.

REFERENCES

[1] L. Breiman, "Random forests," *Machine learning*, vol. 45, no. 1, pp. 5–32, 2001.

[2] N. V. Chawla, K. W. Bowyer, L. O. Hall, and W. P. Kegelmeyer, "SMOTE: synthetic minority over-sampling technique," *Journal of artificial intelligence research*, vol. 16, pp. 321–357, 2002.

[3] D. Möller, "AI4I 2020 Predictive Maintenance Dataset," UCI Machine Learning Repository, 2020. [Online]. Available: https://archive.ics.uci.edu/ml/datasets/AI4I+2020+Predictive+Maintenance+Dataset

[4] F. Pedregosa et al., "Scikit-learn: Machine learning in Python," *Journal of machine learning research*, vol. 12, pp. 2825–2830, 2011.

[5] R. Elwell and R. Polikar, "Incremental learning of concept drift in nonstationary environments," *IEEE Trans. Neural Netw.*, vol. 22, no. 10, pp. 1517–1531, 2011.